FedMSE: IoT 네트워크 침입 탐지를 위한 준지도 연합학습 접근법

저자: Van Tuan Nguyen, Razvan Beuran 소속: 일본 호쿠리쿠 첨단과학기술대학원대학(JAIST); 베트남 Le Quy Don Technical University 원문: arXiv:2410.14121v2 (2025년 4월 3일)

> 번역 안내: 논문의 초록, 본문, 알고리즘, 표, 그림 설명, 결론을 한국어로 옮겼다. SAE, MSEAvg, FedAvg, FedProx 등 모델명과 인용 표기는 유지했으며 참고문헌 서지정보는 검색 가능하도록 원어로 남겼다. 그림 자체의 영문 글자는 원문을 참조할 수 있도록 별도로 설명했다. 수식 번호는 원문과 같다.

초록

본 논문은 IoT 네트워크의 침입 탐지 성능을 개선하기 위한 새로운 연합학습 접근법을 제안한다. IoT의 확산은 사이버 공격 표면을 넓혔으며, 데이터 가용성, 계산 자원, 전송 비용, 특히 개인정보 보호 문제 때문에 전통적인 중앙집중식 머신러닝 방법만으로는 충분하지 않게 되었다. 이러한 문제를 해결하기 위해 Shrink Autoencoder와 Centroid 단일 클래스 분류기(SAE-CEN)를 결합한 준지도 연합학습 모델을 개발했다. 이 모델은 정상 네트워크 데이터를 효과적으로 표현하고 분산 환경에서 이상을 정확하게 식별하여 침입 탐지 성능을 높인다. 또한 정확한 로컬 모델에 더 높은 우선순위를 부여하여 글로벌 모델의 성능을 개선하는 평균제곱오차 기반 집계 알고리즘(MSEAvg)을 도입했다. N-BaIoT 데이터셋과 디리클레 분포를 이용한 다양한 실험 조건에서, 실제 환경의 이질적인 IoT 네트워크를 모사한 결과 탐지 정확도 지표가 93.98 ± 2.90에서 97.30 ± 0.49로 개선되었고, 게이트웨이의 50%만 학습에 참여해도 되므로 학습 비용이 감소했으며 대규모 네트워크에서도 강건함을 보였다.

키워드: 사물인터넷(IoT), 침입 탐지 시스템, 머신러닝, 연합학습

1. 서론

사물인터넷(Internet of Things, IoT)은 교통(Derawi et al., 2020), 의료(Rejeb et al., 2023), 스마트시티(Yadav and Vishwakarma, 2018) 등 여러 산업에서 큰 잠재력을 보이며 주목받는 기술이 되었다. IoT는 수많은 물리적 객체, 즉 사물들이 서로 연결된 네트워크이다(Sharma et al., 2023). 새로운 고도화된 기기가 매일 생산되면서 IoT 시스템의 규모도 빠르게 커지고 있다. 다수의 연결 기기가 생성하는 데이터는 이질적이고 다양하며 복잡하다. 이로 인해 봇넷, 서비스 거부(DoS), 분산 서비스 거부(DDoS), 스푸핑 등 새로운 IoT 이상 행위가 악용할 수 있는 사이버 공격 표면이 증가한다(Vu et al., 2022). 따라서 현대 IoT 네트워크에서 침입 탐지는 필수적인 작업이다.

사이버 위험으로부터 네트워크와 개인정보를 보호하는 효과적인 방법 중 하나는 네트워크 트래픽을 분석하고 감시하는 침입 탐지 시스템(IDS)이다(Sharma et al., 2023; Idrissi et al., 2023). 일부 연구에서는 이를 이상 탐지 시스템이라고도 한다. IoT 네트워크의 알려지지 않은 위협을 탐지하기 위해 머신러닝을 활용하는 최신 IDS가 활발히 연구·도입되고 있다(Sharma et al., 2023; Vu et al., 2022; Wang et al., 2023). 이러한 방법은 지도학습, 준지도학습, 비지도학습의 세 가지로 구분할 수 있다(Chandola et al., 2009).

지도학습은 학습에 사용할 수 있는 모든 데이터에 라벨이 있다고 가정하고 모델을 구축하며, 학습된 모델은 새로운 데이터를 정상 또는 비정상으로 분류한다. 준지도학습 방식은 정상 데이터만 모델 구축에 사용할 수 있다고 가정하고, 새 데이터가 정상 데이터와 얼마나 다른지에 따라 판단한다. 비지도학습은 라벨이 붙은 학습 데이터를 요구하지 않고, 정상 데이터 지점과 비정상 지점이 멀리 떨어져 있다고 암묵적으로 가정한다. 준지도 및 비지도 방법은 알려지지 않은 이상 행위를 탐지할 수 있으므로 침입 탐지에 폭넓게 사용된다.

효과적인 데이터 학습 모델을 개발하는 것뿐 아니라 IoT 네트워크가 계속 확장되는 상황에 대응하기 위한 학습·배포 전략을 선택하는 것도 중요하다. 전통적인 머신러닝은 연결된 장치에서 수집한 모든 데이터를 하나의 서버에 모아 모델을 학습하는

중앙집중식 방식을 사용한다(Guendouzi et al., 2023). 그러나 현대 IoT에서는 학습과 서비스에 필요한 계산 자원, 서버까지의 거리가 수백~수천 마일에 이를 때 발생하는 데이터 지연, 전송 비용, 그리고 장치와 서버 사이에서 데이터 공유 시 발생할 수 있는 유출 및 개인정보 보호 문제가 있다(Abdulrahman et al., 2021). 특히 네트워크 침입 탐지에서 패킷에는 기기 주소, 연결 세션, 이용자 개인정보, 시스템 취약점과 같은 매우 민감한 정보가 포함된다. 이러한 정보를 계속 교환하고 중앙 저장소에 모으는 것은 유출 위험을 높여 심각한 보안 사고로 이어질 수 있다.

이 문제를 해결할 새로운 접근법으로 연합학습(Federated Learning, FL)이 등장했다. 한 대의 고성능 컴퓨터에서 데이터를 수집하고 모델을 학습·제공하는 대신, 각 네트워크 클라이언트의 계산 능력을 활용해 로컬 모델을 분산 학습한다. 원본 로컬 데이터는 외부에서 직접 접근할 수 없도록 보호되며(Abdulrahman et al., 2021), 이후 여러 로컬 모델을 서버에서 글로벌 모델로 집계한다.

최근에는 FL을 네트워크 이상 탐지에 적용하는 연구가 다수 발표되었다(Nguyen et al., 2019; Idrissi et al., 2023; Mothukuri et al., 2022; Zhang et al., 2023). 하지만 대규모 IoT 환경에서 수집한 트래픽은 응용 분야마다 불균형하고, 학습에 쓸 비정상 데이터가 충분하지 않은 경우가 많다. 또한 IoT 기기의 유형과 생성 데이터가 매우 다양하고 네트워크는 계속 확장된다. 글로벌 모델의 집계 방법 역시 새로운 공격을 효과적으로 탐지하면서 자원이 제한된 IoT 장치에서 효율적으로 동작할 만큼 충분히 최적화되어 있지 않다.

이를 해결하기 위해 본 논문은 오토인코더 기반 특징 표현, 평균제곱오차(Mean Squared Error, MSE), 연합학습을 결합한 협력적 IoT 침입 탐지 방법 FedMSE를 제안한다. 논문에서 준비한 데이터셋과 소스코드는 GitHub(https://github.com/dino-chiio/fedmse)에 공개되어 있다. FedMSE는 준지도학습의 미지 공격 식별 능력과 FL의 안전한 학습 과정을 함께 활용한다. 각 IoT 게이트웨이는 중앙 서버에 원본 데이터를 공유하지 않고 자체적으로 처리한 네트워크 데이터만으로 침입 탐지 모델을 학습한다. 로컬 게이트웨이의 탐지 성능을 높이기 위해 Shrink Autoencoder(SAE)를 특징 표현 방법으로, Centroid(CEN)를 단일 클래스 분류기로 사용하는 하이브리드 방식을 채택했다(Cao et al., 2019).

이어 분산학습의 정확도, 효율성, 강건성을 높이기 위해 MSE 기반의 새로운 연합 집계 알고리즘을 개발했다. 이 방법은 학습 과정에서 로컬 모델별 기여도를 고려하고 더 정확한 모델에 높은 가중치를 부여한다. 실험을 통해 IoT 네트워크 침입 탐지에서 제안 방법의 개선 효과를 확인했다.

본 논문의 주요 기여는 다음과 같다.

1. 연합학습과 준지도학습을 이용해 IoT 네트워크 침입 탐지를 위한 안전한 머신러닝을 구현했다.
2. 이질적인 환경에서 IoT 이상 탐지 능력을 높이는 새로운 FL 알고리즘을 제안했다.
3. 널리 사용되는 IoT 데이터셋을 이용해 폭넓은 실험을 수행했다. 결과는 기존의 대표적 방법과 비교해 분산 IoT 침입 탐지의 향상을 보였다.
4. 자원이 제한된 환경과 대규모 IoT 네트워크 모두에서 알고리즘의 강건성을 종합적으로 분석해 실제 적용 가능성을 확인했다.

논문의 구성은 다음과 같다. 2절에서는 배경 지식을 소개하고 3절에서는 연합 침입 탐지 관련 연구를 검토한다. 4절에서 제안 방법을 설명하며 5절에서 실험 설정과 결과를 제시한다. 6절에서는 결론과 향후 연구를 논의한다.

2. 배경 지식

이 절에서는 연합학습을 이용한 침입 탐지 시스템에 필요한 기본 개념을 소개한다.

2.1. 연합학습

연합학습(McMahan et al., 2017)은 데이터 프라이버시에 대한 우려와 스마트폰·IoT 장치 같은 엣지 기기의 계산 능력 증가에 대응하여 분산 방식으로 머신러닝 모델을 학습하는 방법이다. 여러 장치에 분산된 데이터를 중앙 서버로 옮기지 않고 학습할 수 있다. 본 연구에서는 이러한 장치를 클라이언트 또는 게이트웨이라고 부른다. 각 클라이언트의 모델은 로컬 모델, 여러 클라이언트의 업데이트를 통합해 얻은 모델은 글로벌 모델이다.

학습은 글로벌 모델이 목표 정확도 또는 사전에 정해진 종료 조건에 도달할 때까지 여러 통신 라운드에 걸쳐 수행된다(Abdulrahman et al., 2021). 그림 1에 제시된 한 라운드의 과정은 다음과 같다.

1. 모델 초기화: 정해진 선택 비율에 따라 게이트웨이 일부를 뽑는다. 글로벌 모델을 초기화하여 선택된 게이트웨이에 전송한다.
2. 로컬 학습: 각 게이트웨이가 받은 글로벌 모델을 자체 데이터로 학습해 데이터 특성에 맞게 갱신한다.
3. 모델 업데이트 전송: 선택된 장치의 로컬 학습이 끝나면 최적화된 가중치를 글로벌 서버로 보낸다.
4. 글로벌 모델 집계: 서버가 모든 로컬 모델의 업데이트를 통합하여 참여자들의 정보를 반영한 새 글로벌 모델을 만든다.
5. 글로벌 업데이트: 갱신된 글로벌 모델을 네트워크의 클라이언트에 다시 배포하여 이후 예측에 사용한다.

그림 1. 연합학습 메커니즘의 개략도: 초기화 → 로컬 학습 → 모델 업데이트 → 글로벌 집계 → 글로벌 모델 배포.

FL의 성과를 좌우하는 핵심 요소는 집계 알고리즘이다. 대표적인 방법으로 FedAvg(McMahan et al., 2017)와 FedProx(Li et al., 2020)가 널리 사용된다. FedAvg는 각 클라이언트가 가진 데이터 샘플 수에 비례하여 로컬 모델의 파라미터를 가중 평균해 글로벌 모델을 만든다. 데이터가 많은 클라이언트의 집계 기여도가 더 크며, 구현이 단순하고 참여자가 많은 대규모 네트워크에 적합하다(Idrissi et al., 2023). FedProx는 FedAvg와 유사하지만 로컬 손실함수에 정규화 항을 더해 로컬 모델의 파라미터가 직전 글로벌 모델에서 크게 벗어나는 것을 억제한다.

2.2. 오토인코더

오토인코더(Autoencoder, AE)는 입력을 출력에서 재현하도록 학습하는 순전파 신경망이며, 인코더와 디코더로 구성된다(Goodfellow et al., 2016). 데이터셋을 $X = \{x_1, \cdots, x_n\}$, 인코더의 가중치·편향을 $\varphi = (W, b)$, 디코더의 것을 $\Phi = (W', b')$라고 하자. 인코더 e_φ는 입력 x_i를 잠재층의 새로운 특징 공간에 있는 잠재 표현 h_i로 압축하고, 디코더 d_Φ는 이를 원래 특징 공간의 재구성 결과 $\hat{x}_i$로 변환한다.

식 (1a) $h_i = e_\varphi(x_i) = act_e(Wx_i + b)$

식 (1b) $\hat{x}_i = d_\Phi(h_i) = actd(W'h_i + b')$

여기서 act_e와 actd는 각각 인코더와 디코더의 활성화 함수이다. AE는 역전파 기법으로 입력과 재구성값 사이의 차이가 작아지도록 학습한다.

식 (2) $L_AE = (1/n) \Sigma_i \|x_i - \hat{x}_i\|^2$

여기서 n은 데이터 샘플 수다. 정상 데이터로 학습한 AE는 학습 데이터와 비슷한 입력에서 재구성 오차가 작지만 학습한 패턴과 다른 이상 데이터는 정확히 재구성하기 어렵다. 따라서 재구성 오차를 이상 판별 지표로 사용할 수 있고, 오차가 클수록 비정상일 가능성이 높다.

AE는 특히 침입 탐지에서 특징 차원 축소에 유용하다. 복잡한 원본 데이터의 중요한 특성을 잠재층의 저차원 공간에 효과적으로 추출·표현함으로써 다른 머신러닝 모델이 데이터 패턴을 쉽게 학습하게 하고 탐지 시 계산 복잡도도 줄인다.

그림 2. (a) 인코더-잠재층-디코더로 이루어진 AE 구조. (b) AE의 잠재 표현을 이상 탐지 분류기에 입력하는 활용 방식.

원문 그림

그림 1. 연합학습의 작동 방식

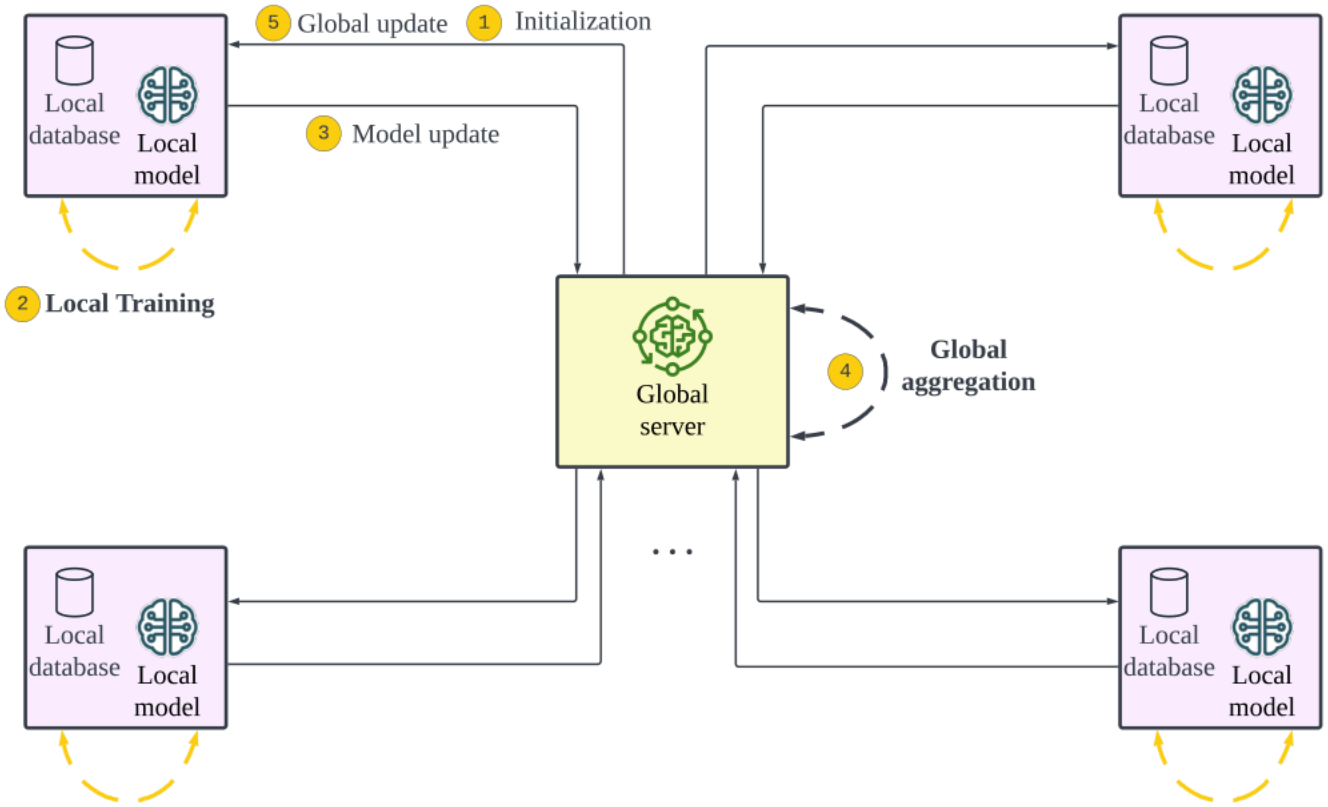
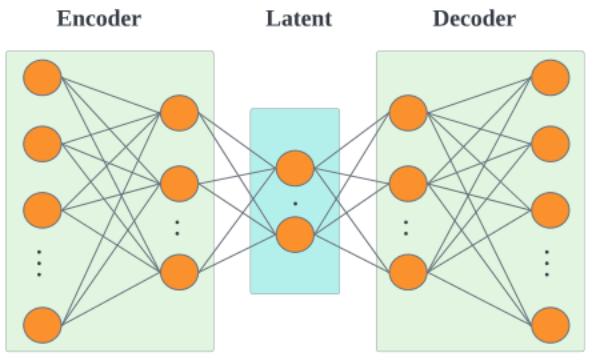
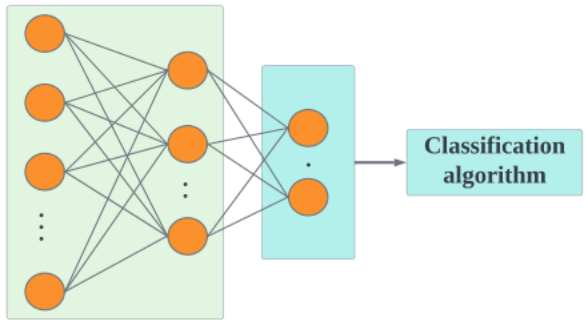


그림 2. 오토인코더 구조와 이상 탐지에의 활용



(a)



(b)

그림 내부의 영문 표기는 원문 그대로 유지함

3. 관련 연구

IoT 네트워크 침입 탐지를 위한 연합학습 연구를 이해하기 위해 최근 연구를 검토한다.

고도화된 침입 탐지에서 가장 큰 문제 중 하나는 라벨이 지정된 비정상 데이터의 부족이다. 현대 IoT 네트워크는 막대한 트래픽을 생성하지만 개인정보 보호, 전문가 부족, 라벨링 비용 등으로 인해 비정상 데이터의 라벨은 충분하지 않다(Cao et al., 2019). 이상 트래픽에는 시스템의 취약점과 약점에 관련된 통신이 포함되므로 관리자는 네트워크 및 클라이언트의 민감한 정보를 보호하기 위해 이를 외부에 공개하지 않으려 한다. 또한 시간이 갈수록 데이터양이 커지고 침입 행위가 복잡해져 실제 네트워크에서 이상 트래픽을 수집·처리·라벨링하려면 상당한 시간과 전문지식이 필요하다.

이처럼 비정상 데이터를 충분히 확보하기 어렵기 때문에, 정상 데이터의 패턴을 모델링하는 준지도 방법(OCSVM, LOF 등)을 활용할 수 있다(Zhang et al., 2015; Breunig et al., 2000). 특히 AE는 복잡한 네트워크 데이터의 특징을 모델링할 수 있어 침입 탐지 분야에서 널리 활용되었다(Cao et al., 2019; Meidan et al., 2018; Idrissi et al., 2023). 정상 데이터를 학습한 뒤 새로운 데이터의 재구성 오차를 이용하며, 오차가 클수록 이상일 가능성이 높다고 본다.

FL의 근본적인 어려움 중 하나는 비독립·비동일분포(non-IID) 데이터의 처리이다(McMahan et al., 2017). 전통적인 중앙집중식 머신러닝은 보통 각 데이터가 독립이고 동일한 분포에서 추출되는 IID 상황을 가정한다. 반면 FL의 클라이언트 데이터는 장치 이용자의 행동과 사용 패턴, 각기 다른 로컬 환경에 의해 만들어지므로 통계적 특성이 다르다(Sattler et al., 2020). 하나의 IoT 네트워크는 서로 다른 위치에서 엣지 서버인 게이트웨이가 관리하는 여러 서브네트워크로 나뉠 수 있다. 서브네트워크마다 사용하는 기기와 응용이 달라 학습 데이터의 양과 분포도 크게 달라진다.

이러한 이질성 때문에 로컬 모델이 전체 네트워크를 충분히 대표하지 못하고, 글로벌 모델의 침입 탐지 성능이 나빠질 수 있다. 따라서 여러 게이트웨이의 기여도를 어떻게 가중할지 신중히 결정해야 한다. 앞서 소개한 FedAvg와 FedProx는 로컬 학습 데이터의 크기를 기준으로 글로벌 모델을 갱신한다. 하지만 참가자의 가용성과 데이터 특성이 계속 달라지는 복잡한 분산 네트워크에서는 표본 수가 많은 클라이언트라고 전체 네트워크를 잘 대표하는 것은 아니다.

FL 기반 IoT 응용에서는 통신 오버헤드와 계산 비용 같은 자원 제약도 중요하다(McMahan et al., 2017; Sattler et al., 2020). 다수의 클라이언트가 분산 학습에 참여하면 통신량과 시간이 늘어난다. IoT 장치의 계산 능력은 제한적이며 학습과 예측을 동시에 수행하는 데 쓸 자원이 많지 않다. 정교한 탐지 방법일수록 계산 활동이 복잡해져 자원 사용량과 사고 대응 시간이 증가할 수 있다. 그러므로 가볍고 강건한 학습 전략이 필수적이다. 일부 연구에서는 AE를 특징 추출·압축에 사용해 차원을 줄임으로써 계산 복잡도를 줄이고 탐지 정확도와 대응 시간을 개선했다(Cao et al., 2019; Nguyen et al., 2024).

IoT 침입 탐지에 FL을 처음 적용한 연구는 GRU 네트워크를 사용하는 기기 유형별 자가학습 프레임워크 DIoT이다(Nguyen et al., 2019). 이 시스템은 IoT 기기의 접근 지점 역할을 하는 보안 게이트웨이와 기기 유형별 모델을 관리하는 IoT 보안 서비스로 구성된다. 사람의 개입이나 라벨링된 데이터 없이 모델을 학습·갱신하여 새로운 기기 행동과 위협에 동적으로 적응한다. 연구진은 30종이 넘는 IoT 기기와 Mirai 봇넷을 활용해 실험실과 실제 스마트홈 환경에서 시험했고, 실제 환경에서 오탐 없이 탐지율 95.6%를 얻었다. 하지만 기기 유형마다 별도 모델을 게이트웨이에서 유지해야 하므로 네트워크가 커지면 관리가 어려울 수 있다. 다양하고 이질적인 IoT 네트워크에서는 게이트웨이의 계산 과부하가 대응 성능에 영향을 줄 수 있으며, 탐지 대상도 Mirai 봇넷에 한정되었다.

Mothukuri 등(2022)은 LSTM과 GRU에 앙상블 학습을 결합하여 장치 내 학습을 가능하게 했다. 각 로컬 GRU 모델은 입력에 대한 공격 유형별 확률을 반환하고, 랜덤 포레스트 분류기(RFC)가 이를 투표처럼 통합해 가장 높은 결합 확률의 라벨을 최종 예측으로 선택한다. 평가에서는 비연합 방식과 비교해 이상 탐지율 99.5%와 매우 적은 오탐을 보였다. 그러나 학습할 때 알려진 공격의 라벨을 사용하는 지도학습 방식이므로 미지 공격 탐지 능력이 제한된다. 또한 예측 단계에서 모든 클라이언트가 새 데이터를 추론해야 해 통신 오버헤드가 크고, 로컬 데이터의 특성을 충분히 고려하지 않아 네트워크 이질성의 영향을 받을 수 있다.

Fed-ANIDS(Idrissi et al., 2023)는 본 연구와 유사하게 AE를 기반으로 하는 준지도 네트워크 침입 탐지 방식이다. 일반 AE, 변분 오토인코더(VAE), 적대적 오토인코더(AAE) 등 여러 모델을 사용해 정상 트래픽의 재구성 오차로 이상을 탐지하고, FedAvg와 FedProx로 연합학습을 수행한다. USTC-TFC2016, CIC-IDS2017, CSE-CIC-IDS2018 데이터셋을 이용한 실험에서 높은 정확도와 낮은 오탐률을 보이면서 프라이버시를 보호했다. FedProx는 FedAvg보다 정확도에서 약간 우수했

다. 하지만 이질적인 네트워크 설정에서는 정상 데이터 전반으로의 일반화가 어려워지고, 학습에서 보지 못한 데이터에 대한 성능이 낮아졌다.

4. 제안 방법

본 논문은 Shrink Autoencoder(AE의 변형)와 Centroid 알고리즘을 결합한 하이브리드 모델에 연합학습을 적용하는 IoT 침입 탐지 방법인 FedMSE를 제안한다. 그림 3의 전체 구조는 FL 체계에 따라 (1) SAE-CEN 하이브리드 침입 탐지기와 (2) MSEAvg 집계의 두 가지 주요 부분으로 이루어진다.

모델에 입력하기 전에 먼저 네트워크 트래픽을 전처리한다. Meidan 등(2018)이 제안한 방식으로 트래픽을 수집하고 표 형태의 특징을 추출한다. 계산 복잡도를 줄이고 모든 특징이 학습에 동등하게 기여하도록 표준 정규화, 즉 Z-score 정규화를 사용한다.

> 식 (3) $z = (x - \mu) / \sigma$

여기서 x는 원본 특징값, μ는 해당 특징의 평균, σ는 표준편차이다.

그림 3. FedMSE 전체 개요. 게이트웨이는 정상 트래픽을 전처리한 후 SAE를 로컬 학습하고 모델을 서버에 전송한다. 서버는 각 로컬 AE 모델의 개발용 데이터 재구성 오차를 계산해 MSEAvg로 글로벌 모델을 집계한다. 갱신된 모델은 게이트웨이로 돌아가며, 탐지 시에는 SAE의 인코더로 얻은 잠재 특징을 CEN 분류기에 입력해 정상·비정상을 판별한다.

4.1. 하이브리드 침입 탐지 접근법

정상 데이터를 모델링하는 AE 기반 모델은 잠재층을 이용해 원래 데이터를 차원이 더 작고 중요한 특성이 잘 드러나는 공간으로 변환할 수 있다. 그러면 기존의 단일 클래스 분류기들도 변환된 데이터에서 이상을 효과적으로 찾는다. 본 연구는 데이터 표현 방법인 SAE와 이상 탐지기인 CEN을 결합한 SAE-CEN 모델을 구성했다.

SAE(Cao et al., 2019)는 학습 데이터가 적더라도 희소하고 차원이 높은 네트워크 데이터를 기존 침입 탐지 알고리즘이 다루기 쉽게 표현해 준다. SAE는 AE 손실함수인 식 (2)에 새로운 정규화 항을 추가한 변형 모델이다. 새 손실함수는 정상 네트워크 데이터가 잠재층에서 더 잘 모이도록 한다.

> 식 (4) $L_SAE = (1/n) \Sigma_i \|x_i - \hat{x}_i\|^2 + \lambda(1/n) \Sigma_i \|h_i\|^2$

여기서 $\hat{x}_i$는 입력 x_i의 재구성 출력, h_i는 잠재 벡터다. 하이퍼파라미터 λ는 재구성 손실과 잠재 벡터를 원점 쪽으로 수축시키는 손실 사이의 균형을 결정한다. 학습은 다음 알고리즘 1에 따라 수행된다.

알고리즘 1. GatewayUpdate: 로컬 모델 최적화

입력: 로컬 정상 데이터 $X = [x_0, \cdots, x_{m-1}] \sim p(x)$; 로컬 에폭 수 I; 크기가 N인 미니배치 집합 B; 학습률 η; 수축 정규화 계수 λ.

출력: 학습된 Shrink Autoencoder.

1. 서버로부터 인코더 초기 가중치 θ_e와 디코더 초기 가중치 θd를 받는다.
2. epoch = 1, ⋯, I를 반복한다.
3. X의 각 미니배치 x_i에 대해 아래 과정을 수행한다.
4. $h_i \leftarrow \text{Encoder}(x_i; \theta_e)$
5. $\hat{x}_i \leftarrow \text{Decoder}(h_i; \theta d)$
6. $L_SAE \leftarrow (1/N)\Sigma_i \|x_i - \hat{x}_i\|^2 + (\lambda/N)\Sigma_i \|h_i\|^2$
7. 기울기 $\nabla\theta_e L_SAE$, $\nabla\theta d L_SAE$를 계산한다.

원문 그림

그림 3. 제안 방법의 전체 구조

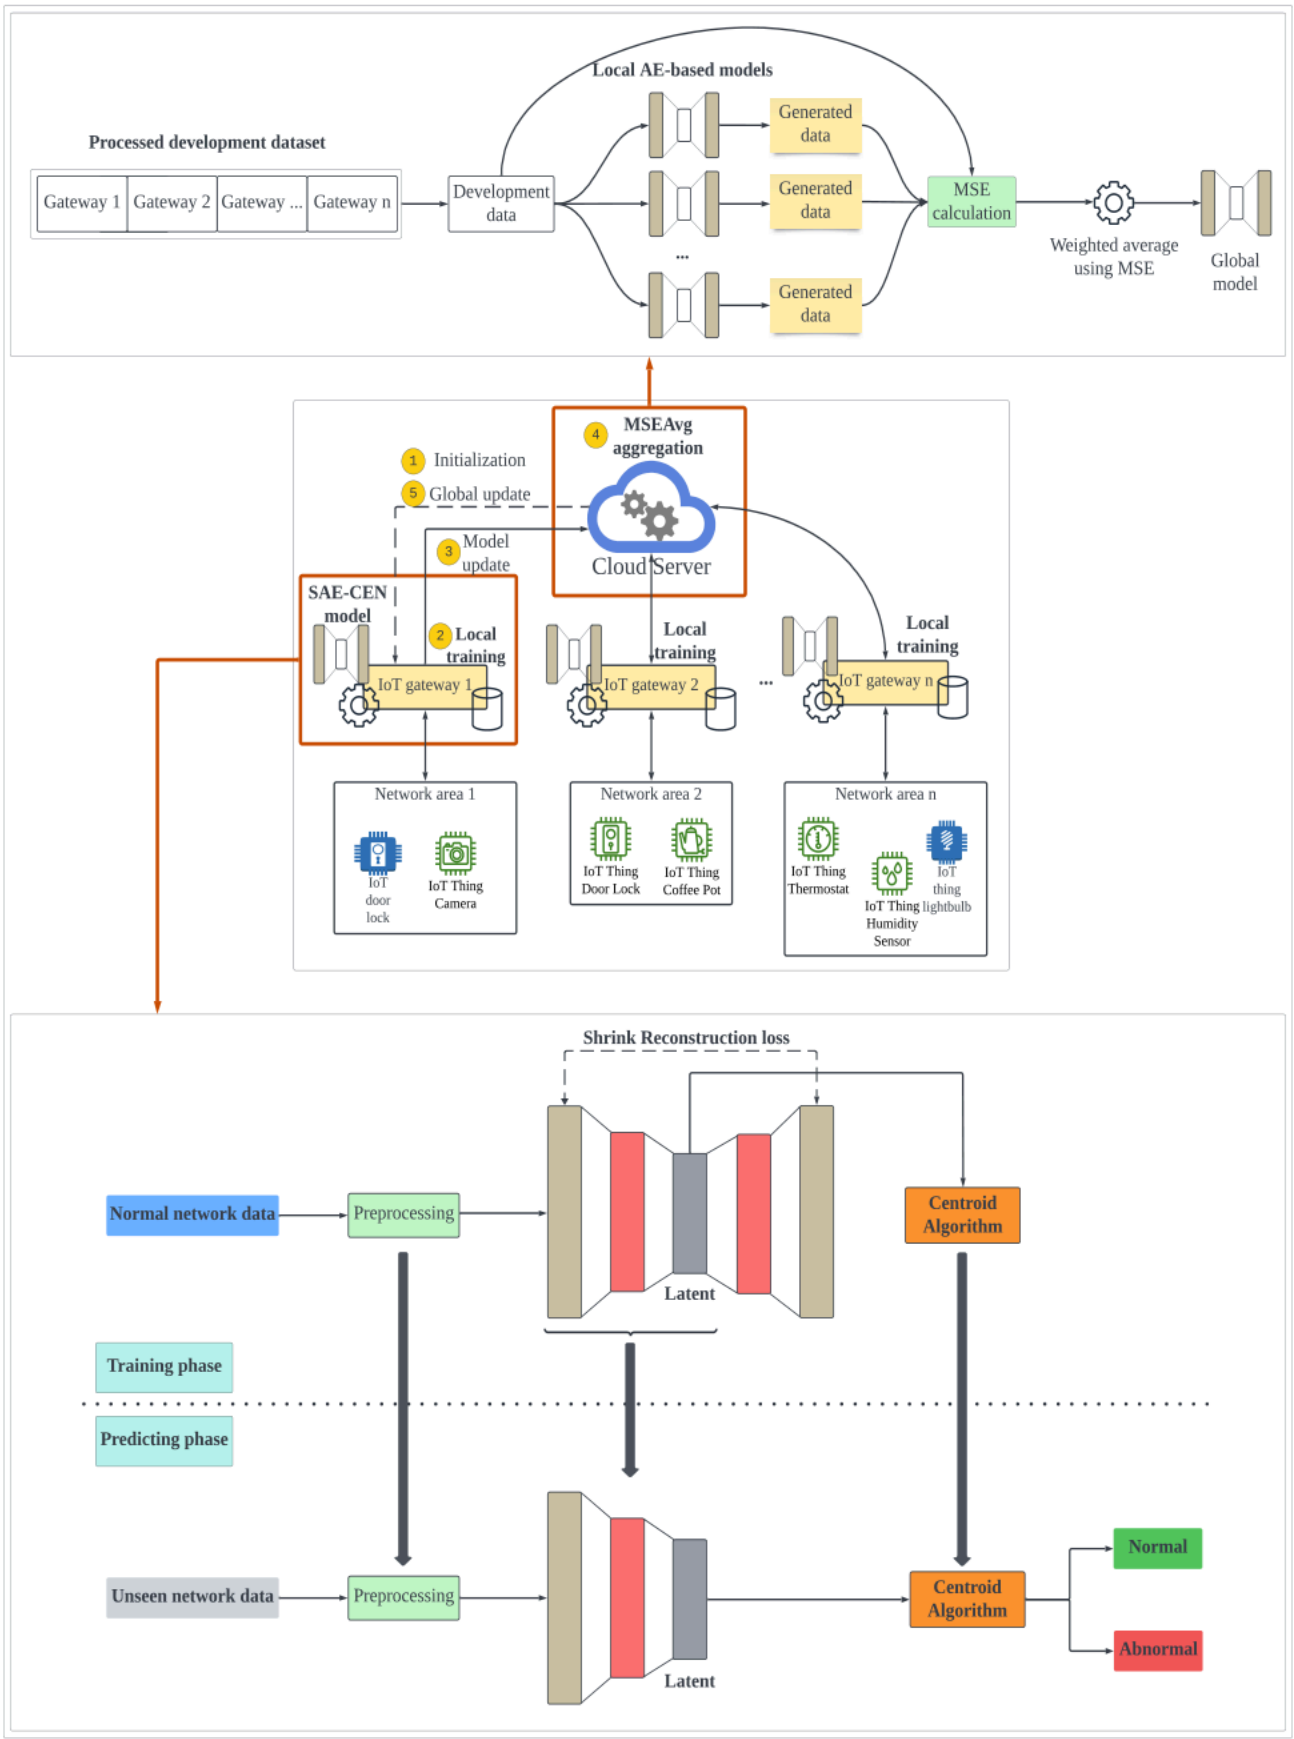


그림 내부의 영문 표기는 원문 그대로 유지함

8. $\theta_e \leftarrow \theta_e - \eta \nabla_{\theta_e} L_SAE$

9. $\theta d \leftarrow \theta d - \eta \nabla_{\theta d} L_SAE$

10. 미니배치 반복을 끝낸다.

11. 에폭 반복을 끝낸다.

12. θ_e와 θd를 글로벌 서버로 전송한다.

정상 네트워크 데이터 집합 $X_0 = \{x_0^{(1)}, \cdots, x_0^{(n)}\}$가 주어졌을 때 침입 탐지의 목적은 새로운 데이터 지점 x가 X_0와 같은 확률적 특성을 가지는지 판단하는 것이다. 간단한 이상 탐지 방식은 X_0가 추출된 분포의 확률밀도함수를 추정해, 새 데이터가 밀도가 낮은 영역에 위치하면 이상으로 표시한다. 그러나 특히 고차원 공간에서는 분포 밀도를 추정하기 어렵다.

다른 간단한 방법은 정상 데이터가 군집 중심에 가깝고 비정상 데이터는 중심에서 멀리 떨어진다고 가정하는 군집 기반 방법이다(Chandola et al., 2009). 이 중 Centroid(CEN) 알고리즘은 관측값과 군집 중심 사이의 거리를 이상 정도, 즉 이상 점수로 사용한다. 점수가 높을수록 비정상일 가능성이 높다. 임곗값을 정하면 정상과 이상으로 분류할 수 있다. CEN은 하이퍼파라미터가 없고 계산 비용도 적은 단순한 알고리즘이다.

서버에서 최적의 SAE 모델을 받은 뒤에는 디코더를 제거하고 인코더만 특징 변환기로 사용하여 CEN이 탐지를 수행하기 쉬운 잠재 표현을 만든다(그림 4). 계산 비용과 사고 대응 시간도 줄어들기 때문에 SAE-CEN은 이상 탐지 능력과 빠른 대응을 함께 확보한다. Cao 등(2019)은 중앙집중식 네트워크 이상 탐지에서 SAE 표현 위에 CEN을 적용했을 때 높은 정확도를 보였다. 본 연구는 이를 분산 IoT 침입 탐지의 FL 환경으로 확장해 평가한다.

그림 4. SAE-CEN 하이브리드 모델의 원리. 원본 특징 공간에서는 정상과 비정상이 뒤섞여 있을 수 있지만, SAE 잠재 공간에서는 정상 데이터가 원점 부근에 밀집하여 CEN이 새 데이터의 이상 여부를 구분하기 쉬워진다.

4.2. 평균제곱오차 기반 모델 집계

모든 연합학습 구조에서 핵심은 글로벌 모델의 집계이다. 집계가 얼마나 효과적으로 이루어지는지가 FL의 성능을 결정한다. 이 절에서는 AE 기반 모델, 특히 SAE-CEN의 성능을 높이기 위한 새로운 집계 알고리즘을 제시한다.

머신러닝 모델을 학습할 때는 과소적합과 과적합을 방지하도록 로컬 및 글로벌 모델의 수렴을 관리해야 한다. 데이터 전처리 단계에서 서버는 각 게이트웨이로부터 정상 네트워크 데이터만 포함하는 소량의 전처리 데이터를 수집한다. 이 데이터를 개발용 데이터(development data)라고 하며 매 라운드 글로벌 모델의 수렴을 검증하는 데 사용한다. 게이트웨이별로 같은 수의 정상 샘플을 무작위로 골라 합치기 때문에 전체 IoT 네트워크를 대표하도록 설계된다. 또한 전처리된 데이터를 사용함으로써 민감한 원본 정보가 로컬 게이트웨이에 남도록 한다.

제안한 MSEAvg 알고리즘은 AE가 정상 데이터를 재구성하는 성능을 활용한다. 각 로컬 모델이 개발용 데이터를 얼마나 정확히 재구성하는지 비교해 글로벌 집계 가중치를 결정한다. 정상 데이터를 잘 재구성하는 모델이 업데이트에 더 큰 영향을 미치게 된다. 그림 3과 알고리즘 2가 전체 과정을 나타낸다.

모든 참여 게이트웨이가 로컬 학습 후 최적 가중치를 서버에 보내면, 서버는 각각의 로컬 모델에 동일한 개발용 데이터를 입력하여 출력의 재구성 오차(MSE)를 계산한다. 오차가 작을수록 정상 데이터를 더 잘 학습한 모델이므로 높은 가중치를 준다. 이후 글로벌 모델은 다음과 같이 집계된다.

식 (5) $W_{global} = (\sum_{i=1}^{n} \alpha_i \cdot W_i) / (\sum_{i=1}^{n} \alpha_i)$

여기서 W_i는 로컬 모델 i의 가중치, α_i는 해당 모델의 MSE에 기반한 집계 가중치다.

식 (6) $\alpha_i = 1 / MSE_i$

여기서 MSE_i는 개발용 데이터에 대한 로컬 모델 i의 평균제곱오차이다.

알고리즘 2. GlobalAgg: MSEAvg 집계

원문 그림

그림 4. SAE-CEN 하이브리드 모델의 원리

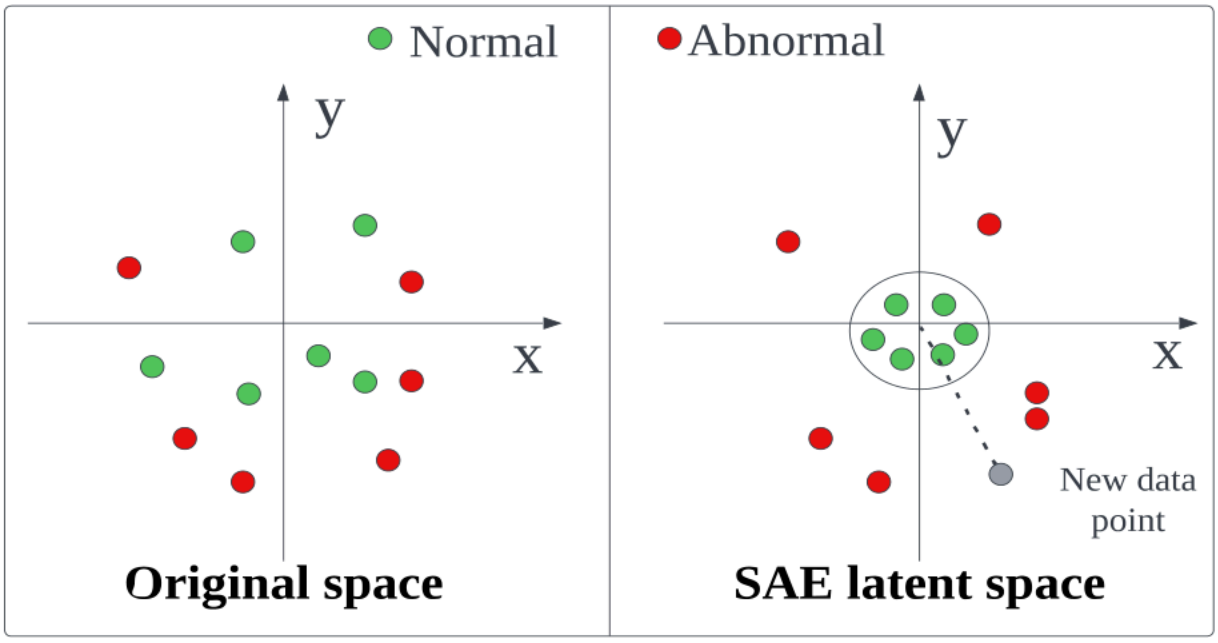


그림 내부의 영문 표기는 원문 그대로 유지함

입력: 글로벌 라운드 수 E; 로컬 모델 집합 L = {L_1, ⋯, L_n}; 개발용 데이터셋 D.

출력: 업데이트된 글로벌 모델 M.

1. 집계 가중치 목록 update_weights ← []로 초기화한다.
2. L의 각 로컬 모델 L_i를 순회한다.
3. 해당 모델의 재구성 데이터 $\hat{D}_i$ ← L_i(D)를 구한다.
4. 유사도 점수 sim_score ← Mean_Squared_Error(D, $\hat{D}_i$)를 계산한다.
5. 집계 가중치 w_i ← 1 / sim_score를 구한다.
6. (L_i, w_i)를 update_weights에 추가한다.
7. 모든 로컬 모델의 처리를 마친다.
8. 수집된 로컬 모델과 가중치를 사용한다.
9. M ← ($\Sigma_i L_i \cdot \alpha_i$) / ($\Sigma_i \alpha_i$)로 글로벌 모델을 계산한다.
10. 가중 집계를 마친다.
11. 갱신된 M을 탐지에 사용할 수 있도록 모든 게이트웨이에 전송한다.

MSEAvg는 개발용 데이터에 대한 재구성 정확도가 높은 로컬 모델의 기여도를 크게 만들어, AE 기반 글로벌 연합 모델을 개선한다. 이는 정상 데이터를 잘 표현한다는 AE 기반 이상 탐지의 기본 목표와 집계 과정을 일치시켜 강건하고 신뢰할 수 있는 글로벌 모델을 만든다.

또한 MSE는 MAE(평균절대오차)보다 큰 재구성 오차를 제곱해 더 크게 반영하므로 성능이 나쁜 모델의 영향을 줄이는 데 유리하다. 오차가 큰 모델은 집계 가중치가 훨씬 작아지고, 오차가 작은 모델은 더 많이 기여한다. 학습 샘플 수를 가중치로 사용하는 FedAvg·FedProx와 달리 MSEAvg는 성능 기반 기준을 적용한다. 대표성이 있는 개발용 데이터로 평가하므로 로컬 데이터가 non-IID여도 비교적 공정하게 모델을 평가할 수 있다. 데이터가 많은 특정 게이트웨이에 과적합될 위험을 줄여 글로벌 모델의 일반화 성능과 신뢰성을 높인다.

5. 평가

제안 방법을 평가하기 위해 세 가지 연구 질문에 대응하는 실험을 수행했다.

1. RQ1: 제안 방법은 IoT 연합 침입 탐지에서 어떻게 동작하는가? → 실험 1(5.2절).
2. RQ2: 학습에 참여하는 게이트웨이의 선택 비율은 연합 침입 탐지에 어떤 영향을 미치는가? → 실험 2(5.3절).
3. RQ3: 제안 방법은 대규모 IoT 네트워크에서 어떻게 동작하는가? → 실험 3(5.4절).

5.1. 실험 설정

5.1.1. IoT 네트워크 구성

FL의 non-IID 문제를 고려하여 이질성이 낮은 경우(low non-IIDness)와 이질성이 높은 경우(high non-IIDness)의 두 시나리오를 실험한다. 첫 번째 상황에서는 각 게이트웨이가 같은 네트워크 토폴로지, 장치 유형, 응용을 사용해 서브네트워크 간 데이터 분포가 유사하다고 가정한다. 두 번째 상황에서는 서브네트워크마다 토폴로지, IoT 기기 유형, 응용, 장치 유형별 데이터 수가 모두 다르다고 가정한다.

실험을 실제 환경에 가깝게 하기 위해 N-BaIoT 데이터셋에서 정상 데이터의 일부를 사용했다. N-BaIoT(Meidan et al., 2018)는 IoT 봇넷 공격 탐지를 위해 만들어졌으며, 시판 IoT 장치 9종을 Mirai와 Gafgyt 봇넷에 감염시켜 수집한 데이터이다. 표 1은 장치별 데이터 수를 나타낸다.

표 1. N-BaIoT 데이터셋의 장치별 정상·Gafgyt·Mirai 데이터 샘플 수

ID	장치 이름	정상	Gafgyt	Mirai
0	Danmini_Doorbell	49,548	652,100	316,650
1	Ecobee_Thermostat	13,113	512,133	310,630
2	Philips_B120N10_Baby_Monitor	175,240	312,273	610,714
3	Provision_PT_737E_Security_Camera	62,154	330,096	-
4	Provision_PT_838_Security_Camera	98,514	309,040	429,337
5	Samsung_SNH_1011_N_Webcam	52,150	323,072	-
6	SimpleHome_XCS7_1002_WHT_Security_Camera	46,585	303,223	513,248
7	SimpleHome_XCS7_1003_WHT_Security_Camera	19,528	316,438	514,860
8	Ennio_Doorbell	39,100	316,400	-

그림 5는 실험 데이터 배분을 나타낸다. 네트워크는 10개의 IoT 게이트웨이로 구성했다. 각 게이트웨이의 데이터는 랜덤 알고리즘과 제약 조건을 이용하여 N-BaIoT에서 뽑아 non-IID 특성을 재현했다. Gutierrez 등(2024)에 따라 게이트웨이 수 n과 집중도 파라미터 α를 가지는 디리클레 분포 $\mathrm{Dir}_n(\alpha)$, 그리고 Jensen-Shannon(JS) 거리를 사용해 네트워크의 이질성을 통제했다.

동질적인 설정에서는 각 장치 유형 k에 대해 $p_k \sim \mathrm{Dir}_{10}(1000)$에서 비율을 뽑고, 그중 $p_{k,j}$에 해당하는 데이터를 게이트웨이 j에 배정했다. 이때 JS = 0.01이다. 이질적인 설정에도 같은 절차를 적용하지만 α = 0.1995, JS = 0.83으로 설정했다. 테스트 단계에서는 네트워크가 동적으로 변하는 상황을 모사하도록 일부 새로운 장치를 추가했다. RQ3의 네트워크 규모 효과를 평가하기 위해 동일한 방법으로 20·30·40·50개 게이트웨이 규모에서도 두 설정의 데이터를 구성했다.

그림 5. 실험 시나리오별 데이터 할당. (a) 이질성이 낮은 학습 데이터, (b) 이질성이 높은 학습 데이터, (c) 이질성이 낮은 테스트 데이터, (d) 이질성이 높은 테스트 데이터. 학습 데이터는 정상 샘플만 포함한다. 테스트 데이터는 정상·비정상 샘플 모두를 포함하며 일부 서브네트워크에 새 IoT 장치가 등장한다.

5.1.2. 하이퍼파라미터 설정

본 연구는 FedAvg, FedProx, MSEAvg를 적용한 AE와 SAE-CEN의 성능을 비교한다. 침입 탐지에서는 정상을 이상과 구분하는 정확한 임곗값을 정하기 어렵다. 따라서 서로 다른 임곗값 전반에서 모델을 평가하는 ROC 곡선 아래 면적(AUC) 지표를 사용한다(Huang and Ling, 2005). Rey 등(2022)의 N-BaIoT 실험을 참고해 각 실험을 5번 실행하고 AUC의 평균과 표준편차를 구했다.

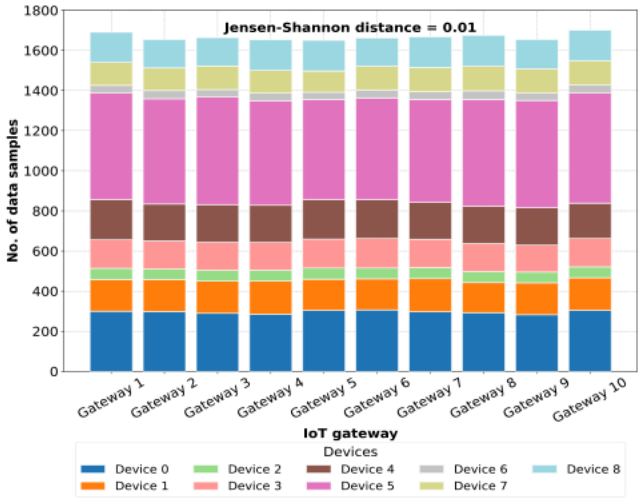
학습 데이터에 이상 샘플이 없기 때문에 하이퍼파라미터를 튜닝하기 어렵다. 따라서 일반적으로 사용하는 값으로 설정했다. 미니배치 크기는 12, 학습률 lr = 0.00001, 로컬 에폭 I = 100, 글로벌 라운드 E = 20, FedProx 근접항 계수 μ = 0.001로 설정했다. 매 라운드 전체 게이트웨이의 절반을 무작위로 선택해 학습에 참여시켰다. SAE의 수축 파라미터는 Cao 등(2019)을 따라 λ = 10으로 두어 수축 손실과 MSE 손실 사이의 균형을 맞췄다. 로컬 모델 학습에는 Adam 최적화(Kingma and Ba, 2014)와 조기 종료(Prechelt, 2012)를 사용했다.

각 게이트웨이의 로컬 학습 데이터를 실제 학습 40%, 검증 10%, 개발용 데이터셋 40%, 테스트 집합에 추가 10%로 나누었다. 게이트웨이마다 개발용 데이터의 수를 동일하게 하기 위해 개발용 샘플이 가장 적은 게이트웨이의 수에 맞췄다. 글로벌 서버에서도 개발용 데이터에 대한 수렴을 관리하기 위해 조기 종료를 적용했다. AE 계열 모델의 잠재층 뉴런 수는 Cao 등(2016)의 경험적 규칙에 따라 $m = \lfloor 1 + \sqrt{n} \rfloor$로 설정했다. n은 원래 특징 공간의 차원이다.

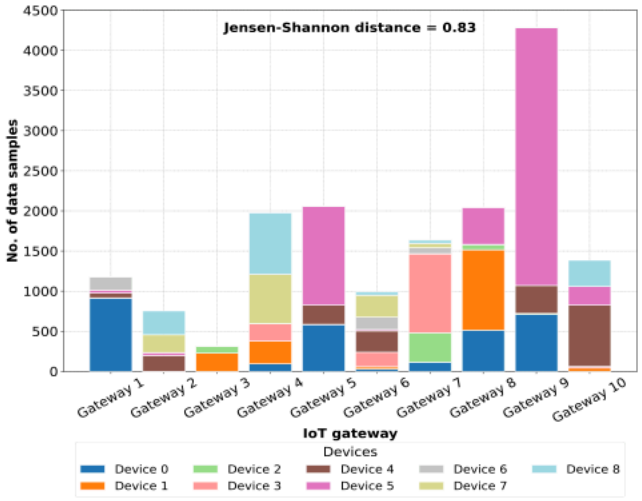
모든 실험은 Python으로 구현했고, 일본 JAIST의 KAGAYAKI 고성능 GPU 서버에서 실행했다. 이 서버는 Intel Xeon GOLD 5320 52코어 2.2 GHz CPU, 512 GB DDR4/3200 메모리, NVIDIA A100 48 GB GPU 2개를 갖추고 있다.

원문 그림

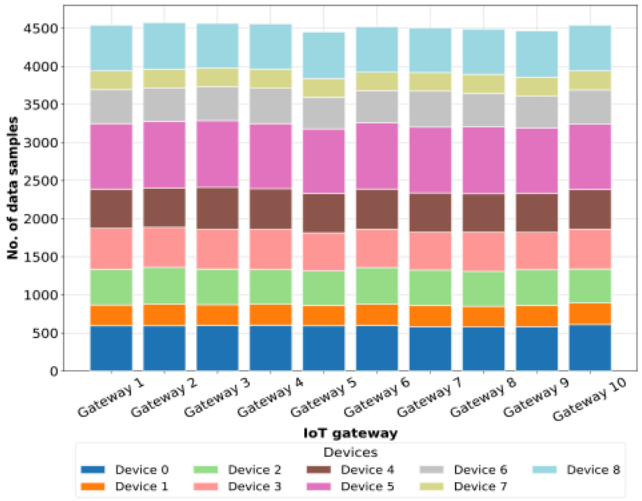
그림 5. 실험 시나리오별 데이터 할당



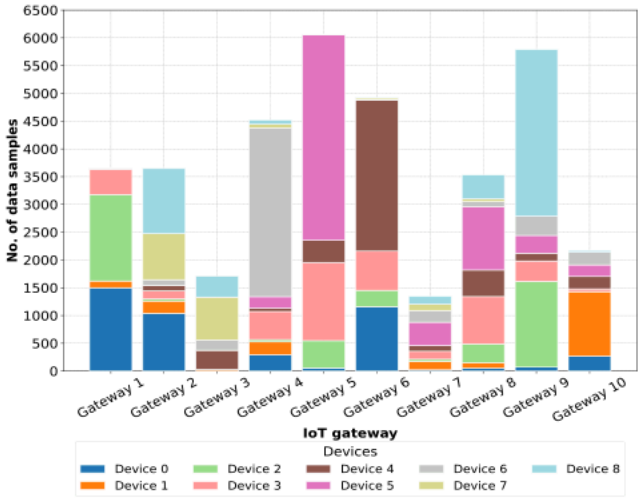
(a) Training data with low non-IIDness



(b) Training data with high non-IIDness



(c) Testing data with low non-IIDness



(d) Testing data with high non-IIDness

그림 내부의 영문 표기는 원문 그대로 유지함

5.2. 실험 1: 연합 침입 탐지 성능

첫 번째 실험에서는 네트워크의 각 게이트웨이에서 제안 방법의 탐지 성능을 조사했다. 표 2와 그림 6·7은 AE와 SAE-CEN을 세 가지 집계 알고리즘으로 학습했을 때 얻은 AUC를 나타낸다. 데이터의 non-IID 정도가 높아지면 머신러닝 모델의 이상 탐지가 어려워져 정확도가 감소하고 게이트웨이별 결과의 일관성도 낮아진다.

표 2. 이질성이 낮거나 높은 환경에서 게이트웨이별 AUC(%) 열 순서는 AE+FedAvg, AE+FedProx, AE+MSEAvg, SAE-CEN+FedAvg, SAE-CEN+FedProx, SAE-CEN+MSEAvg이다. 마지막 열 조합이 FedMSE이다.

(a) 낮은 non-IID

게이트웨이	AE/FedAvg	AE/FedProx	AE/MSEAvg	SAE-CEN/FedAvg	SAE-CEN/FedProx	SAE-CEN/MSEAvg
1	98.77±0.33	98.53±0.51	98.54±0.42	97.93±0.75	97.67±1.18	98.68±0.64
2	97.81±0.50	97.53±0.59	97.51±0.73	97.73±0.75	97.76±0.73	97.83±0.82
3	98.43±0.47	98.10±0.57	98.02±0.58	97.80±0.55	97.74±0.49	98.26±0.85
4	99.42±0.20	99.39±0.25	99.32±0.30	99.22±1.00	98.52±0.82	99.31±0.70
5	99.75±0.10	99.75±0.04	99.73±0.07	99.84±0.06	99.81±0.07	99.86±0.05
6	99.23±0.26	99.16±0.31	99.09±0.35	98.92±0.92	98.22±0.69	99.16±0.41
7	98.30±0.35	98.08±0.45	98.06±0.39	97.82±0.78	97.59±1.28	98.30±0.79
8	100.00±0.00	100.00±0.00	100.00±0.00	100.00±0.00	100.00±0.00	100.00±0.00
9	99.03±0.17	98.94±0.17	98.93±0.20	98.38±0.76	98.06±1.22	98.72±0.54
10	99.97±0.02	99.97±0.02	99.97±0.02	99.95±0.02	99.95±0.03	99.95±0.02
평균	99.07±0.24	98.95±0.29	98.92±0.31	98.76±0.56	98.53±0.65	99.01±0.48

(b) 높은 non-IID

게이트웨이	AE/FedAvg	AE/FedProx	AE/MSEAvg	SAE-CEN/FedAvg	SAE-CEN/FedProx	SAE-CEN/MSEAvg
1	91.00±4.84	87.96±6.25	86.61±1.92	96.65±1.00	97.44±1.62	97.25±1.04
2	99.58±0.03	99.58±0.03	99.56±0.00	99.62±0.05	99.61±0.09	99.64±0.09
3	88.68±5.76	87.70±5.87	86.80±4.84	93.55±1.09	93.82±1.30	94.58±0.89
4	89.42±5.14	88.72±4.93	86.14±2.48	94.40±1.11	94.41±1.66	94.97±1.03
5	97.96±1.19	97.53±1.17	96.91±0.28	98.63±0.47	98.76±0.62	98.69±0.46
6	92.70±3.52	91.75±3.90	89.47±1.13	93.84±2.03	95.38±0.87	94.43±0.25
7	94.62±2.81	93.94±3.25	92.53±0.53	96.18±0.34	96.63±0.94	96.58±0.58
8	95.84±2.14	95.47±2.20	94.18±0.94	97.51±0.55	97.87±0.50	97.73±0.07
9	98.05±1.39	97.65±1.33	97.04±0.50	99.14±0.33	99.02±0.71	99.30±0.42
10	99.52±0.09	99.52±0.09	99.48±0.00	99.77±0.05	99.81±0.10	99.77±0.05
평균	94.74±2.69	93.98±2.90	92.87±1.26	96.93±0.70	97.28±0.84	97.30±0.49

그림 6. 이질성이 낮은 환경에서 게이트웨이별 연합 침입 탐지 정확도. 그림 7. 이질성이 높은 환경에서 게이트웨이별 연합 침입 탐지 정확도.

원문 그림

그림 6. 비IID 정도가 낮을 때 게이트웨이별 성능

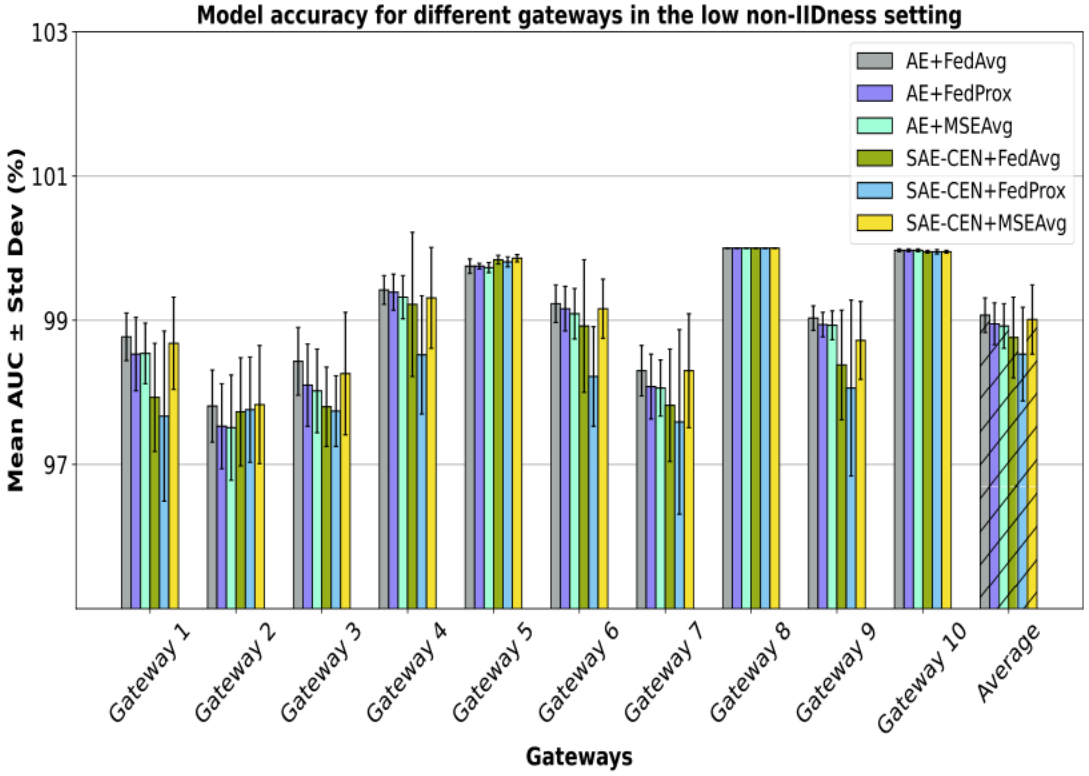


그림 7. 비IID 정도가 높을 때 게이트웨이별 성능

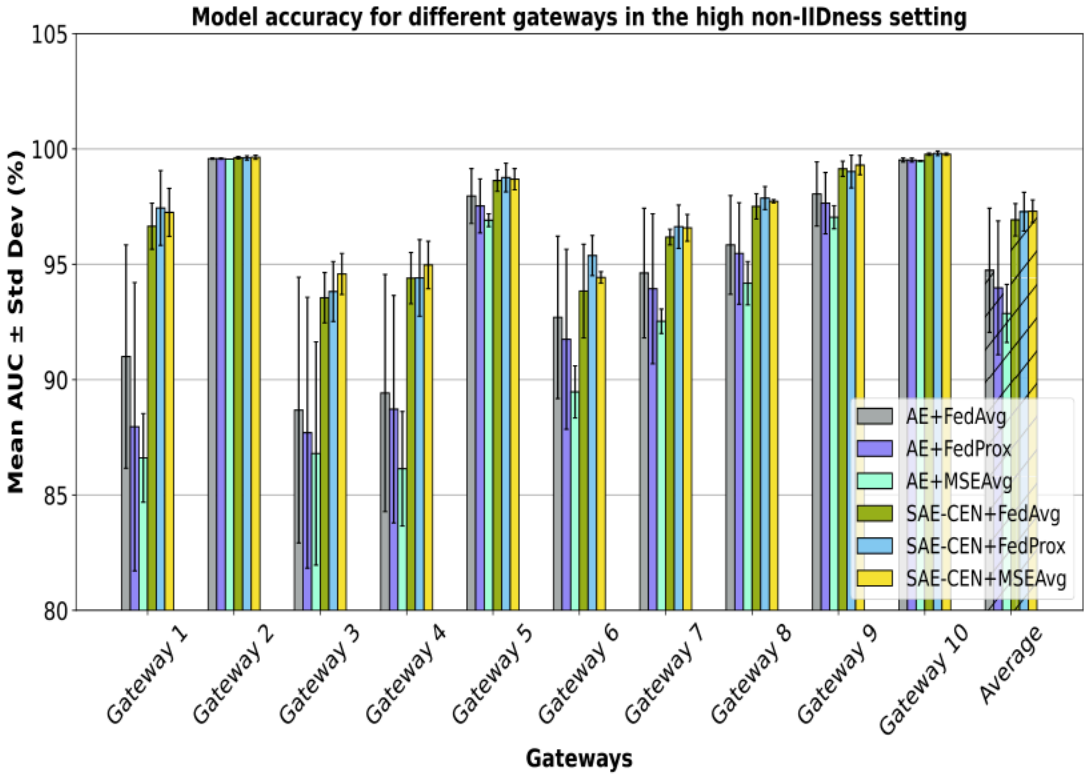


그림 내부의 영문 표기는 원문 그대로 유지함

이질성이 낮은 경우 AE와 SAE-CEN은 모든 연합학습 알고리즘에서 모든 게이트웨이에 높은 정확도를 보였으며, 일부 조합에서는 AE가 SAE-CEN보다 조금 더 좋았다. 게이트웨이별 학습 데이터 분포가 거의 같기 때문에 AE가 전체 데이터를 쉽게 일반화하고 충분히 잘 모델링할 수 있기 때문이다. 반면 SAE는 정상 데이터를 원점에 가깝게 표현하는 목표와 정상 데이터를 재구성하는 목표 사이에 균형을 맞춰야 한다. 이로 인해 첫 번째 시나리오에서는 SAE-CEN의 성능 향상이 두드러지지 않는다. 즉, 단순한 FL 환경에서는 AE만으로도 정확한 이상 탐지가 가능하다.

하지만 이질성이 높은 환경에서는 모든 집계 방법에서 AE의 정확도가 크게 떨어지는 반면 SAE-CEN은 모든 게이트웨이에서 높은 효과를 보였다. 게이트웨이별 학습 데이터 분포가 크게 달라 각 로컬 AE가 서로 다른 방향으로 수렴하고, 이를 하나의 글로벌 모델로 합치면 성능이 나빠질 수 있기 때문이다. 반대로 각 로컬 SAE-CEN은 정상 데이터의 잠재 표현을 원점 부근의 작은 공간으로 모으도록 최적화된다. 따라서 집계된 모델도 잠재 데이터를 적절한 영역에 가깝게 표현하고, CEN이 보지 못한 데이터를 효과적으로 판별하도록 돕는다.

특히 이질성이 높은 환경에서는 MSEAvg와 SAE-CEN의 결합인 FedMSE가 개선된 결과를 보여 주었다. 더 작은 표준편차는 게이트웨이 간 성능 일관성이 좋아졌음을 의미한다. FedAvg와 FedProx는 선택된 게이트웨이의 학습 데이터 수를 기준으로 모델을 집계하지만, 두 번째 시나리오에서는 데이터가 많은 게이트웨이가 전체 데이터를 가장 잘 대표한다고 보장할 수 없다. 예를 들어 그림 5(b)의 게이트웨이 5가 게이트웨이 6보다 반드시 더 나은 것은 아니다. MSEAvg는 전체를 대표하는 데이터를 더 잘 모델링하는 로컬 업데이트에 높은 우선순위를 부여한다.

정확한 모델의 가중치를 크게 설정하면 집계 결과가 그 모델들에 가까워져 글로벌 모델의 일반화 능력이 향상되고, 이상 데이터를 정상 잠재 공간에 섞이게 할 수 있는 품질 낮은 업데이트의 영향을 줄인다. 또한 SAE는 재구성 오차와 수축 오차의 균형을 맞춰야 하는데, MSEAvg는 잠재 표현 능력을 유지하면서 정상 데이터를 포괄적으로 모델링하도록 돕는다. 그 결과 정상 데이터와 비정상 데이터를 FedAvg·FedProx보다 잘 분리한다.

그림 8은 SAE의 테스트 잠재 데이터를 2차원 및 3차원으로 시각화한 것이다. MSEAvg로 형성된 정상 군집은 FedAvg·FedProx보다 작고 밀도가 높으며 원점에 더 가깝다. 따라서 새로운 IoT 기기가 도입되어도 FedMSE의 CEN 모델이 비정상 데이터를 더 효과적으로 탐지할 수 있다.

그림 8. 세 연합 집계 알고리즘에서 SAE의 잠재 표현을 2차원·3차원으로 비교한 그림. 정상 데이터의 응집 정도가 방법별로 다르다.

5.3. 실험 2: 게이트웨이 선택 비율의 영향

FL에서 한 학습 라운드에 참여하도록 선택된 게이트웨이의 비율은 모델의 성능, 효율성, 통신 오버헤드에 큰 영향을 미친다. 적절한 선택 비율을 정할 때 이 요소 사이에는 절충 관계가 있다. 두 번째 실험은 자원이 제한된 IoT 네트워크에서 FedMSE의 효율성을 평가하기 위해 수행되었다.

표 3과 그림 9·10은 게이트웨이 선택 비율을 바꾸었을 때 비교 대상 모델의 평균 AUC를 보여 준다. 비율 변화는 게이트웨이 간 일관성에 영향을 주지만 FedMSE는 여전히 강력한 성능을 나타낸다. 평균 정확도가 약간 변동하는 동안 FedAvg, FedProx, MSEAvg 모두 SAE-CEN을 비교적 비슷한 정확도로 학습시키며, 차이는 주로 표준편차와 계산 비용에서 확인된다.

표 3. 게이트웨이 선택 비율에 따른 AUC(%) 비교 FedMSE는 SAE-CEN/MSEAvg 열에 해당한다.

(a) 낮은 non-IID

참여 비율	AE/FedAvg	AE/FedProx	AE/MSEAvg	SAE-CEN/FedAvg	SAE-CEN/FedProx	SAE-CEN/MSEAvg
50%	99.07±0.24	98.95±0.29	98.92±0.31	98.76±0.56	98.53±0.65	99.01±0.48
60%	98.48±0.44	98.12±0.45	98.47±0.37	98.76±0.42	98.85±0.56	98.96±0.68
70%	98.13±0.70	98.17±0.56	98.04±0.54	98.51±0.74	98.69±0.37	98.44±0.67
80%	97.96±0.93	97.77±0.69	97.66±0.78	98.77±0.85	98.79±0.54	98.71±0.80

원문 그림

그림 8. 연합학습 방식별 SAE 잠재 표현 비교

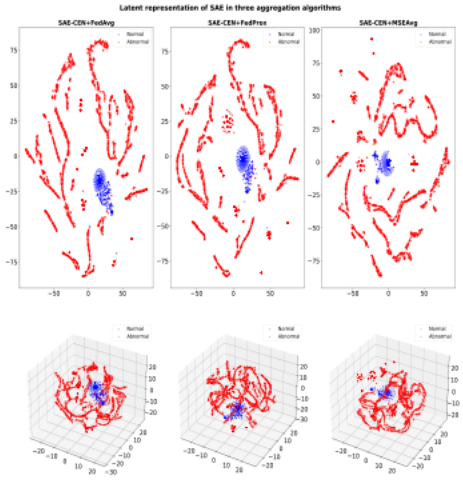


그림 9. 비IID 정도가 낮을 때 참여 비율별 성능

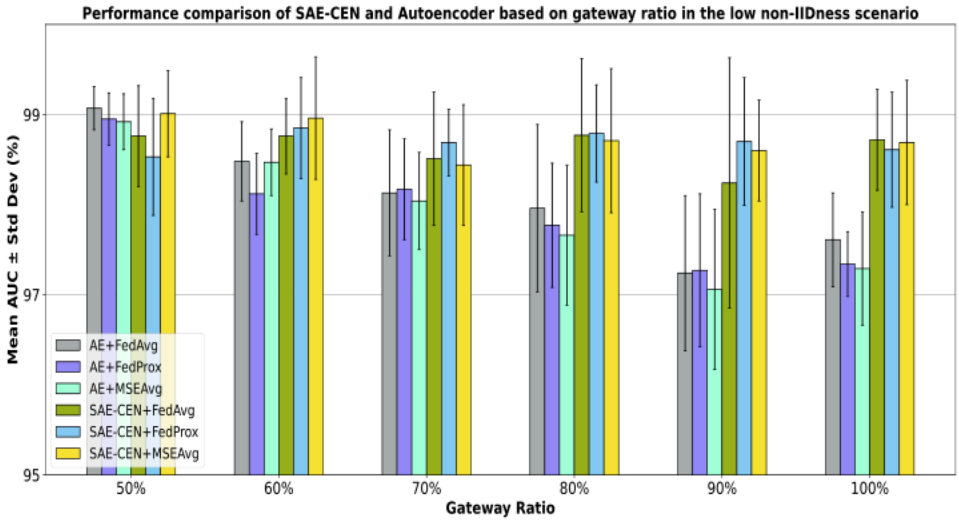


그림 10. 비IID 정도가 높을 때 참여 비율별 성능

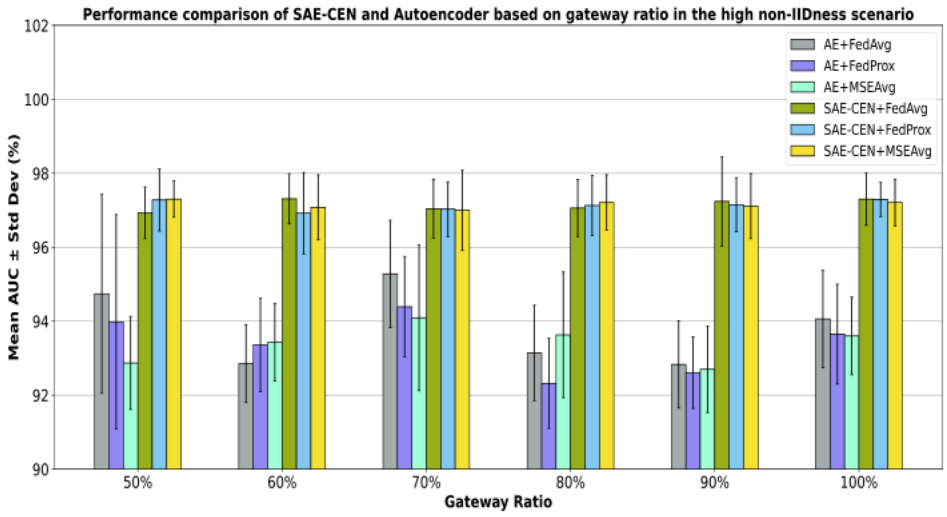


그림 내부의 영문 표기는 원문 그대로 유지함

참여 비율	AE/FedAvg	AE/FedProx	AE/MSEAvg	SAE-CEN/FedAvg	SAE-CEN/FedProx	SAE-CEN/MSEAvg
90%	97.24±0.86	97.27±0.85	97.06±0.89	98.24±1.39	98.70±0.71	98.60±0.56
100%	97.61±0.52	97.34±0.36	97.29±0.63	98.72±0.56	98.61±0.64	98.69±0.69

(b) 높은 non-IID

참여 비율	AE/FedAvg	AE/FedProx	AE/MSEAvg	SAE-CEN/FedAvg	SAE-CEN/FedProx	SAE-CEN/MSEAvg
50%	94.74±2.69	93.98±2.90	92.87±1.26	96.93±0.70	97.28±0.84	97.30±0.49
60%	92.85±1.05	93.36±1.26	93.43±1.05	97.31±0.68	96.92±1.10	97.08±0.88
70%	95.28±1.45	94.39±1.36	94.09±1.97	97.04±0.80	97.03±0.74	97.00±1.09
80%	93.14±1.29	92.32±1.22	93.63±1.70	97.06±0.77	97.13±0.81	97.21±0.75
90%	92.83±1.18	92.61±0.97	92.70±1.17	97.24±1.21	97.15±0.73	97.11±0.88
100%	94.06±1.31	93.65±1.35	93.60±1.05	97.30±0.71	97.29±0.46	97.21±0.63

그림 9. 이질성이 낮은 시나리오에서 게이트웨이 참여 비율별 정확도. 그림 10. 이질성이 높은 시나리오에서 게이트웨이 참여 비율별 정확도.

이질성이 낮으면 데이터가 게이트웨이마다 균일하게 분포하므로 모든 게이트웨이는 비슷한 특성을 가진다. 따라서 전체의 일부만 학습에 참여하더라도 대표성 있는 데이터를 제공할 수 있고, 참여 비율에 관계없이 표준편차가 낮아 성능이 일관적이다. AE는 잡음에 민감하므로 더 많은 게이트웨이가 업데이트에 참여하면 정확도가 떨어지는 경향이 있다. 게이트웨이 사이의 작은 분포 차이들이 집계 시 잡음과 변동성을 증가시키기 때문이다. 반면 SAE-CEN은 앞서 설명한 특징 표현 능력 덕분에 참여 비율을 바꾸어도 정확하고 안정적으로 동작한다.

이질성이 높은 경우에는 데이터 분포가 균일하지 않아 표준편차가 더 커지고 게이트웨이 사이의 성능 차이가 두드러진다. 정확도 경향은 이질성이 낮을 때와 비슷하지만, 모든 설정에서 SAE-CEN은 정확도와 일관성 양쪽 모두 AE보다 뛰어나다. 전체 게이트웨이가 참여하면 FedAvg·FedProx로 학습한 AE의 표준편차가 줄어드는 경향이 있다. 전체 데이터 분포를 업데이트에 반영해 일반화가 개선되기 때문이다. MSEAvg는 대체로 FedAvg·FedProx보다 표준편차가 작아 게이트웨이 사이에서 보다 안정적인 성능을 보인다.

현재 게이트웨이 선택은 무작위이므로 선택된 집합이 전체 모집단을 제대로 대표한다는 보장은 없다. 참여 비율이 낮으면 어떤 게이트웨이가 다른 것보다 자주 선택되는 편향이 발생해 그 게이트웨이에 과적합되고 네트워크 전체에서 높은 분산이 나타날 위험이 있다. 그러나 MSEAvg처럼 대표성이 있는 개발용 데이터를 기반으로 더 정확한 로컬 모델을 우선하는 집계는 이러한 영향을 일부 상쇄한다. 그래서 적은 수의 게이트웨이만으로도 글로벌 모델의 일반화와 일관성을 유지할 수 있다.

IoT 게이트웨이는 계산 자원이 제한되어 있으므로 계산 비용도 엄격히 고려해야 한다. 참여 비율이 높을수록 매 라운드에 더 많은 게이트웨이가 학습하여 계산 부하, 통신량, 학습 시간이 증가한다. 첫 번째 시나리오에서는 AE와 FedAvg만으로도 50%의 낮은 참여 비율에서 충분한 성능을 얻는다. 하지만 실제에 가까운 이질적 상황에서는 SAE-CEN이 더 좋은 선택이다. 다른 집계 알고리즘과 결합해도 SAE-CEN은 좋은 성능을 내지만, FedMSE는 단지 절반의 게이트웨이를 이용하면서도 높은 정확도와 일관성을 달성한다. 이는 성능과 계산 비용을 모두 고려한 목표에 부합한다. 두 시나리오 모두 적합한 모델을 고르면 50% 참여만으로 충분하며, 전반적으로 실제 IoT 환경에서 FedMSE가 더 유리한 방법이라고 결론내린다.

5.4. 실험 3: IoT 네트워크 규모에 따른 정확도

IoT 네트워크는 사용 중 초기 상태보다 규모가 크게 바뀔 수 있으므로 이러한 동적 특성에 강건한 모델이 필요하다. 세 번째 실험은 다양한 네트워크 크기에서 제안 방법의 강건성을 확인한다. 표 4와 그림 11·12는 게이트웨이 선택 비율을 50%로 고정하고 실험 1과 유사한 하이퍼파라미터로 설정했을 때 모델의 평균 성능을 보여 준다.

표 4. 네트워크 규모별 AUC(%) 비교 FedMSE는 SAE-CEN/MSEAvg 열에 해당한다.

(a) 낮은 non-IID

게이트웨이 수	AE/FedAvg	AE/FedProx	AE/MSEAvg	SAE-CEN/FedAvg	SAE-CEN/FedProx	SAE-CEN/MSEAvg
10	99.07±0.24	98.95±0.29	98.92±0.31	98.76±0.56	98.53±0.65	99.01±0.48
20	98.43±0.26	98.51±0.21	98.56±0.31	98.59±0.37	99.02±0.39	98.54±0.37
30	97.40±0.67	97.45±0.47	97.37±0.57	98.27±0.43	98.34±0.50	98.34±0.55
40	97.05±0.97	97.16±0.66	96.95±0.95	98.38±0.42	98.38±0.42	98.45±0.39
50	97.01±0.75	96.74±0.56	97.20±0.82	98.33±0.63	98.16±0.37	98.20±0.56

(b) 높은 non-IID

게이트웨이 수	AE/FedAvg	AE/FedProx	AE/MSEAvg	SAE-CEN/FedAvg	SAE-CEN/FedProx	SAE-CEN/MSEAvg
10	94.74±2.69	93.98±2.90	92.87±1.26	96.93±0.70	97.28±0.84	97.30±0.49
20	95.72±1.42	95.62±1.18	95.68±1.11	97.17±0.90	97.19±0.83	97.29±0.96
30	96.95±1.51	96.96±1.19	96.98±1.43	97.54±0.61	97.65±0.54	97.73±0.56
40	95.99±1.83	95.78±1.78	95.72±1.80	97.81±0.94	97.58±0.84	97.77±1.01
50	96.30±0.98	96.39±0.85	96.42±2.37	98.41±0.72	98.36±0.65	98.52±0.51

그림 11. 이질성이 낮은 환경에서 네트워크 규모별 정확도. 그림 12. 이질성이 높은 환경에서 네트워크 규모별 정확도.

IoT 네트워크 규모가 커지면 FL은 게이트웨이 사이의 데이터 변동성 및 지식을 효과적으로 일반화하는 능력 사이에서 균형을 조절해야 한다. 이 연구는 실제 네트워크를 모사하기 위해 9종의 IoT 장치를 사용한다. 같은 종류의 장치에서 생성한 데이터 분할은 비슷한 분포를 가질 수 있다. 따라서 장치 유형 집합과 참여 비율을 고정하면, 더 큰 네트워크에서 선택된 학습 데이터가 작은 네트워크보다 전체를 잘 대표할 수 있다. 하지만 참여자가 많아지면 집계 과정에서 잡음도 증가해 FL이 불안정해질 수 있다.

이질성이 낮은 환경에서 네트워크가 커질수록 AE 성능은 감소하는 경향을 보였다. 실험 2에서 논의한 것처럼 디리클레 분포로 조절해도 게이트웨이 사이에 작은 분포 차이는 남아 있으며, AE는 잡음에 민감하다. 네트워크가 커지면 더 많은 게이트웨이가 학습에 참여해 잡음과 변동성이 점차 증가하지만, 이미 분포가 균일하므로 일반화 측면에서 얻는 이득은 크지 않다. 따라서 AE는 비교적 동질적인 경우에도 대규모 네트워크에서 효율적으로 동작하지 못할 수 있다. 반면 SAE-CEN은 강력한 특징 표현 능력으로 높은 성능을 유지한다.

이질성이 높은 환경에서 FedMSE의 효과는 더 뚜렷하다. 표 4에서 대부분의 조건에서 뛰어나고 가장 높은 정확도를 나타낸다. 네트워크가 커짐에 따라 SAE-CEN 정확도도 증가하는 추세를 보인다. 게이트웨이별 학습 데이터가 서로 다르기 때문에 참여자가 늘어날수록 글로벌 모델이 더 다양한 지식을 얻고 전체 네트워크의 정상 패턴을 효과적으로 학습할 수 있기 때문이다. 특히 MSEAvg를 적용하면 이 효과가 두드러진다. 이 실험은 제안 방법이 이질적인 대규모 네트워크에서도 높은 성능을 유지함을 보여 준다.

6. 결론

본 논문은 중앙집중식 머신러닝의 한계인 프라이버시 문제, 통신 오버헤드, 데이터 가용성에 대응하면서 IoT 네트워크 침입 탐지를 개선하기 위한 새로운 연합학습 방법을 제안했다. AE 기반 모델을 사용하는 준지도 연합학습을 도입해 이질적인 IoT 네트워크에서 탐지 정확도와 강건성을 높였다. 주요 기여는 SAE와 Centroid 알고리즘을 결합한 하이브리드 모델 SAE-CEN을 FL 환경에 적용한 것과, 평균제곱오차를 기반으로 하는 새로운 집계 알고리즘 MSEAvg를 개발한 것이다. 이를 통해 데이터 이질성, 불균형 분포, 자원 제약, IoT 네트워크의 동적 변화와 같은 문제에 대응한다.

원문 그림

그림 11. 비IID 정도가 낮을 때 네트워크 규모별 성능

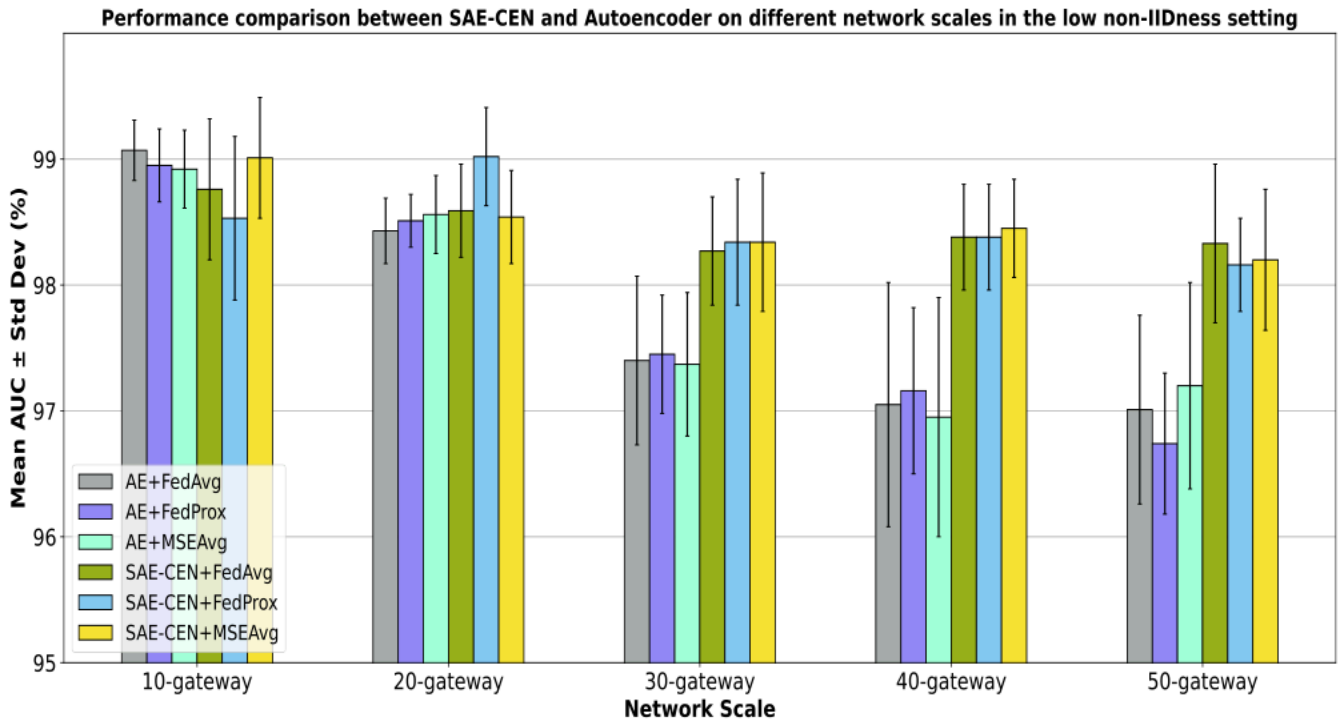


그림 12. 비IID 정도가 높을 때 네트워크 규모별 성능

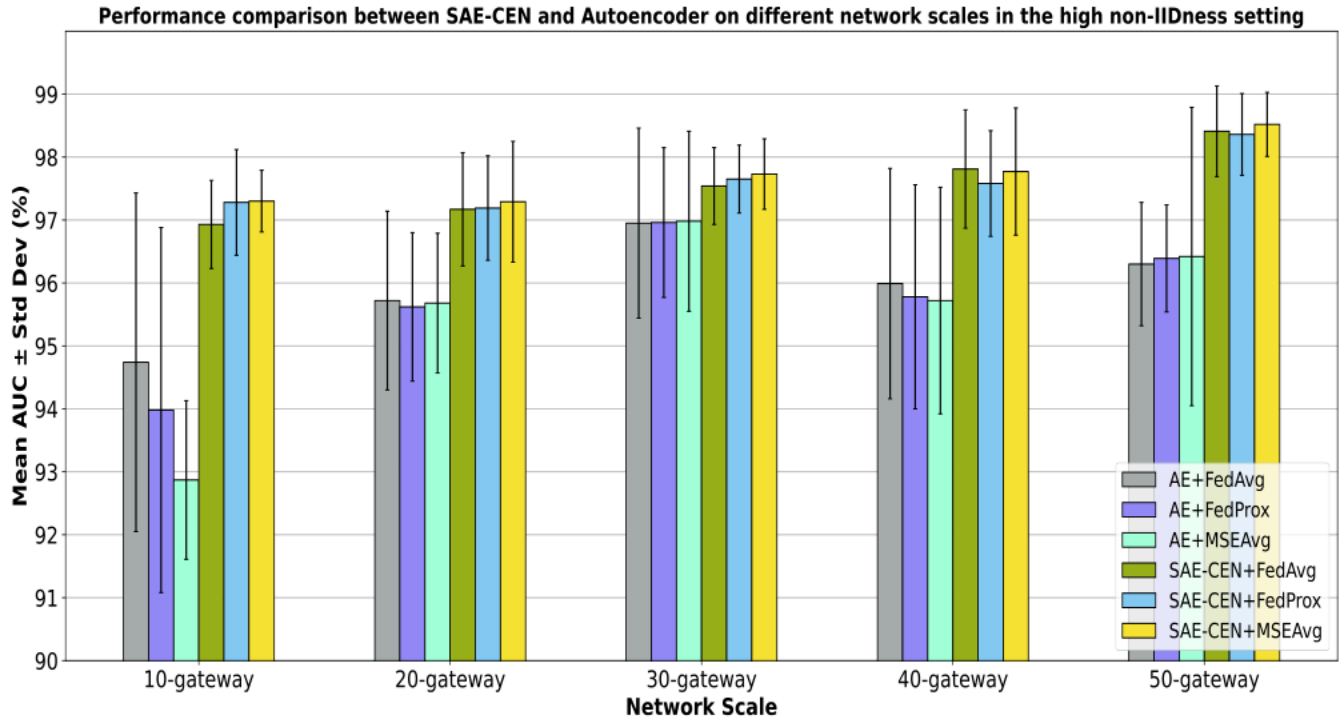


그림 내부의 영문 표기는 원문 그대로 유지함

N-BaIoT 데이터셋의 실험에서 제안 방법은 AUC 97.30 ± 0.49를 달성했다. 이는 AE+FedAvg의 94.74 ± 2.69, AE+FedProx의 93.98 ± 2.90보다 높은 값이다. 또한 학습 과정에 게이트웨이의 50%만 참여하도록 하여 자원 사용량과 통신 오버헤드를 줄이면서도 대규모 IoT 네트워크에서 강건함을 유지했다.

그러나 하이퍼파라미터에 민감하며, 데이터가 이질적인 FL 환경에서는 더 효과적인 게이트웨이 선택 전략이 필요하다는 한계가 있다. MSEAvg 역시 서버에서 추가 계산을 수행하므로 계산 비용이 증가한다. 평가한 사이버 위협의 범위도 Mirai와 Gafgyt 봇넷 두 종류로 제한되었다. 향후에는 실제 네트워크에서 성능을 평가할 수 있는 종단 간(end-to-end) 실험 프레임워크를 구현하고, 계층적 학습 등 새로운 기법을 통합해 집계 알고리즘을 개선하고, 현실 환경에 맞게 하이퍼파라미터를 최적화해야 한다. 다른 IoT 네트워크 데이터셋을 이용한 추가 실험도 필요하다. 이러한 문제를 해결하면 끊임없이 변화하는 IoT 보안 요구사항을 더욱 잘 충족할 수 있다.

저자 기여도(CRediT)

- Van Tuan Nguyen: 연구 개념화, 방법론, 정형 분석, 검증, 초안 작성.
- Razvan Beuran: 지도·감독, 원고 검토 및 편집.